ESIEE Paris · E5-BIO · 2026/2027 · Akram REDJDAL

Projet de NLP en santé

Extraction d'informations et question answering

Travail en binôme · Septembre à novembre 2026

1 Présentation du projet

Vous allez construire et évaluer **deux outils NLP** : l'un extrait des informations médicales dans des documents textuels ; l'autre répond à des questions à partir de documents. Vous comparerez plusieurs approches et expliquerez leurs résultats.

Une **mention** est un fragment de texte ; sa catégorie indique son type. Dans « Pas de fièvre, mais une toux », l'extraction retrouve les deux symptômes. Une étape séparée indique que « fièvre » est niée.

Le **question answering (QA)** produit une réponse avec les passages qui la justifient, appelés **preuves**. Un document peut préciser qu'un entretien précède l'examen sans en indiquer la durée : l'outil doit alors signaler que cette durée n'est pas fournie.

1.1 Le socle attendu

Partie	Travail obligatoire
Extraction	Un corpus annoté, **au moins deux catégories**, une méthode par dictionnaire ou règles et une méthode apprise ; comparaison évaluée.
Négation	**20 phrases fictives**, mentions cibles fournies ; règles de négation, évaluation et analyse des erreurs.
Corpus QA	Environ **10 documents** pour commencer ; **20 questions de développement** annotées et un **test séparé de 10 questions**.
Réponses QA	Une recherche lexicale ; un passage restitué (Q0) ; un LLM avec deux prompts (Q1/Q2) ; évaluation automatique et manuelle.

1.2 Comment commencer ?

Constituez votre binôme et préparez une **fiche d'une page** : corpus d'extraction, deux catégories, thème du QA, trois sources candidates, moyens de calcul et difficulté éventuelle. Faites valider ce cadrage avant de préparer l'ensemble des données.

Les méthodes seront étudiées progressivement. **Réutilisez les notebooks de cours et de TD** : adaptez ses entrées et vérifiez les sorties. Citez les ressources reprises et expliquez vos modifications. Consultez le guide pratique au besoin ; les échéances figurent à la section 6.

2 Extraction d'informations

2.1 Choisir et explorer les données

Choisissez **un corpus annoté et au moins deux catégories** de mentions. CADEC, QUAERO, BC5CDR et BioRED sont des points de départ décrits dans le guide pratique. Vous pouvez proposer **un autre corpus, dans la langue de votre choix**, en vérifiant son accès, ses annotations et sa compatibilité avec les outils disponibles.

Les annotations doivent localiser les mentions dans le texte ou dans les tokens. Une étiquette globale par document, comme un diagnostic, ne suffit pas pour cette tâche. Retenez des catégories, par exemple maladies et substances, plutôt qu'une liste de deux mots. Conservez aussi les textes sans mention cible : ils permettent d'observer les fausses détections.

1. Chargez les données avec un notebook de lecture. Affichez cinq exemples et repérez le texte, les catégories et les positions des mentions.
2. Comptez les documents et les mentions par catégorie dans chaque partition. Conservez un identifiant de document, même si les données sont découpées en phrases.
3. Vérifiez dix mentions de l'entraînement : leurs positions doivent retrouver exactement les mots annotés. Précisez si ces positions sont des indices de caractères ou de tokens.

Présentez dans la fiche du corpus sa source, sa version, ses conditions d'utilisation, les catégories retenues, les effectifs et quelques exemples. Vérifiez rapidement la faisabilité ; un blocage d'accès ou de conversion se discute en TD.

2.2 Séparer apprentissage, réglage et évaluation

Partition	Utilisation
TRAIN	Apprendre le modèle et construire le dictionnaire à partir des annotations.
VALIDATION	Choisir les paramètres, les règles et la configuration à conserver.
TEST	Évaluer les configurations retenues, sans nouveau réglage.

Conservez les partitions officielles lorsqu'elles existent. Sinon, définissez avec l'enseignant un découpage reproductible par documents, par exemple 70/15/15. Les phrases d'un même document restent ensemble ; traitez les doublons avant la séparation. Sauvegardez les identifiants de chaque partition.

Une annotation **BIO** attribue une étiquette par token : B commence une mention, I la poursuit, O est extérieur aux catégories retenues. Pour les mentions imbriquées ou discontinues, utilisez une convention explicite, identique pour les deux méthodes ; le guide pratique précise ce point.

2.3 Construire une première méthode par dictionnaire ou règles

Recueillez les formes annotées dans TRAIN, par catégorie, puis recherchez-les dans les textes de VALIDATION. Fixez les choix de casse, de variantes et de priorité entre mentions concurrentes. Ajoutez des expressions régulières lorsqu'un motif de surface le justifie.

Inspectez dix sorties, dont des textes sans entité cible, puis calculez les scores. Conservez le texte original et les positions : une normalisation ne doit pas décaler les mentions. **Les annotations de TEST ne servent pas à enrichir le dictionnaire.**

2.4 Comparer une méthode apprise

Réutilisez un parcours du cours : classifieur au niveau des tokens, encodeur gelé avec une tête apprise, ou adaptation supervisée d'un encodeur comme BERT. Une méthode légère peut remplir le socle ; BERT n'est pas imposé.

1. Adaptez le chargement et les labels, puis entraînez sur TRAIN. Avec un tokenizer en sous-mots, vérifiez l'alignement des étiquettes.
2. Commencez par les paramètres du notebook. Choisissez sur VALIDATION la configuration retenue ; une recherche exhaustive n'est pas attendue.
3. Reconstruisez les mentions avec les mêmes catégories et conventions que la méthode par règles.
4. Comparez sur VALIDATION, puis figez les deux méthodes et évaluez-les sur TEST. Sauvegardez leurs prédictions, paramètres, scores et temps mesurés.

Expliquez **cinq erreurs d'extraction** : forme inconnue, mauvaise frontière, confusion de type, etc. S'il y en a moins, présentez celles observées et des cas limites. Une méthode simple peut obtenir le meilleur résultat : votre conclusion doit suivre les observations.

2.5 Étudier séparément la négation

Une mention niée reste à extraire. L'exercice suivant répond à une autre question : *la présence de ce qui est nommé est-elle explicitement niée ?* Les mentions cibles sont fournies à la méthode de négation ; on évalue ainsi cette décision séparément de l'extraction.

1. Générer (avec une IAg si vous voulez) **20 phrases fictives** : 10 avec une mention niée et 10 avec une mention non niée. Indiquez la mention, ses positions, le label et sa justification. Si vos catégories se prêtent mal à cet exercice, utilisez des symptômes fictifs dans la même langue. Attention, la partie détection de la négation doit être développée avant de générer les phrases fictives, vous ne pouvez pas construire une détection de négation spécifique aux phrases générées.
2. Écrivez un guide d'annotation d'une page. Les deux membres annotent séparément, puis comptent et résolvent leurs désaccords.
3. Séparez les familles de formulation en **10 exemples de développement et 10 de test**, avec 5 exemples de chaque label (mention niée ou pas) dans chaque ensemble. Gardez les paraphrases d'un même cas ensemble.
4. Sur le développement, adaptez les règles de détection de négation du notebook : indice de négation, portée et exceptions. Figez les règles, puis évaluez les 10 exemples réservés.

Incluez des négations simples, des coordinations et des cas comme « impossible d'exclure ». **Non nié ne signifie pas confirmé** : une hypothèse peut être incertaine sans être niée. Ce jeu rédigé par ses auteurs est un test contrôlé, pas une estimation sur des dossiers réels.

À conserver pour le jalon extraction

Fiche du corpus, partitions, dictionnaire ou règles, méthode apprise, prédictions et scores des deux méthodes ; jeu de négation, guide et résultats ; synthèse de 2 à 3 pages. Les mesures et le barème sont précisés dans les sections 5 et 7.

3 Constituer le corpus de questions-réponses

3.1 Définir le thème et le public

Votre QA utilise deux ensembles : des **documents** dans lesquels rechercher l'information et des **questions avec réponses de référence** pour vérifier la qualité de l'outil. Vous construisez ces données ; ce travail fait partie de l'évaluation.

Formulez l'usage en une phrase : « Cet outil aide [public] à retrouver [informations] dans [documents] ». Le thème et la langue sont indépendants du corpus d'extraction. Délimitez un sujet que vous pouvez traiter avec un petit ensemble de textes.

Thème	Exemple de périmètre et point de départ
Cancer	Examens ou soins de support pour un cancer choisi ; Institut national du cancer.
Nutrition	Repères alimentaires pour un public défini ; Manger Bouger.
Sport	Activité physique et sédentarité ; Manger Bouger.
Santé mentale	Présentation d'un trouble et de ses accompagnements ; Psycom.
Neurologie	Comprendre une pathologie ; dossiers Inserm.
Biocapteurs	Principe et limites d'une famille de capteurs ; articles et documents techniques.

Les liens sont regroupés dans le guide pratique. D'autres thèmes ou sources sont possibles après validation du cadrage. Le projet analyse les informations des textes ; il ne vise pas le conseil médical personnalisé ni l'analyse de signaux de capteurs.

3.2 Préparer les documents et les passages

Commencez par **environ 10 documents substantiels**. Augmentez vers 20 seulement si les questions l'exigent ; adaptez ce repère avec l'enseignant pour des textes très longs ou très courts.

1. Choisissez des documents cohérents par leur thème, leur langue et leur public. Commencez par trois fichiers dont le texte est sélectionnable.
2. Créez un catalogue : identifiant, titre, organisme, URL, date ou version et date de récupération. Vérifiez les conditions d'utilisation et supprimez les doublons.
3. Extrayez le texte avec le notebook. Comparez un extrait à sa source, puis retirez les en-têtes et éléments de navigation répétés.
4. Découpez en **passages**, d'abord selon les paragraphes et les sections. Conservez pour chacun un identifiant, le texte, le document et sa localisation dans la source.
5. Contrôlez dix passages, dont le plus court et le plus long : ordre du texte, nombres, unités et négations. Gardez le contexte nécessaire à leur compréhension.

Une fois le corpus constitué, conservez les mêmes documents sources et leur version pour DEV et TEST. Si vous ajustez le découpage sur DEV, actualisez les identifiants des preuves à partir de leur localisation source, sans modifier les questions ni les éléments attendus. Les documents externes sont joints au rendu seulement si leur redistribution est autorisée ; sinon, fournissez le catalogue et la procédure d'accès. N'utilisez pas de dossiers personnels issus d'un stage ou de votre entourage.

3.3 Rédiger et répartir les questions

Votre binôme prépare **30 questions annotées**, réparties **avant les réglages de l'outil** en deux jeux distincts :

- **DEV : 20 questions pour la mise au point** ; 16 avec réponse, dont au moins 4 nécessitant deux passages complémentaires, et 4 sans réponse ;
- **TEST : 10 questions pour l'évaluation finale** ; 8 avec réponse, dont au moins 2 nécessitant deux passages complémentaires, et 2 sans réponse.

Gardez les reformulations d'une même question dans le même jeu. Pour chaque question répondable, rédigez une référence concise, listez les éléments indispensables et associez les preuves à chacun. Pour une question sans réponse, justifiez l'absence d'information dans l'ensemble des documents, même si une réponse existe ailleurs.

L'autre membre du binôme relit la question, la réponse et les preuves. Consignez les désaccords et leur résolution dans un court guide de rédaction. Une aide du LLM à la formulation est possible si elle est déclarée ; les références restent vérifiées dans les sources **avant de lire les réponses de l'outil évalué**.

Cas pédagogique fictif

Passage P01 : « Le guide propose un entretien d'information avant l'examen. »
Question : « Quelle étape est proposée avant l'examen ? »
Référence : « Un entretien d'information. » Élément attendu : entretien avant l'examen.
Preuve : P01.
« Quelle est la durée de cet entretien ? » est sans réponse si aucun autre document ne fournit cette durée.

Premier contrôle : présentez trois documents et cinq questions annotées à l'enseignant avant de constituer tout le corpus. Lorsque les documents permettent de préparer les questions demandées et leurs preuves, vous pouvez arrêter la collecte.

3.4 Mettre au point sur DEV, puis évaluer sur TEST

DEV sert à choisir les réglages : découpage, recherche de passages et prompts. Ses réponses et preuves de référence permettent de comprendre les erreurs. Le socle QA utilise un LLM préentraîné dont les poids ne sont pas modifiés ; ces 20 questions ne constituent pas un jeu d'entraînement ou de fine-tuning.

Mettez TEST de côté jusqu'au gel des configurations. Exécutez ensuite Q0/Q1/Q2 sur ses 10 questions, sauvegardez toutes les prédictions, puis calculez les scores et analysez les réponses. Ne changez plus les réglages à partir de ces résultats. Les questions TEST ne servent pas d'exemples dans les prompts.

4 Comparer les méthodes de question answering

Un **LLM** produit du texte à partir d'un **prompt** : consigne, question et passages. Le **RAG** associe recherche et génération. Le socle utilise un **modèle préentraîné sans fine-tuning** ; DEV sert à régler la recherche et les prompts.

ID	Méthode	Sortie attendue
Q0	Recherche lexicale, puis restitution	Le premier passage classé et son identifiant.
Q1	Même recherche + LLM, prompt simple (zero shot)	Une réponse fondée sur les passages, avec citations.
Q2	Même recherche + même LLM, prompt structuré (few shot, chain of thoughts ou autres)	Une réponse avec contraintes explicites, citations et consigne d'abstention.

4.1 Retrouver les passages et produire Q0

1. Réutilisez le notebook de recherche lexicale, par exemple BM25, pour classer les passages selon la question.
2. Sauvegardez les **cinq premiers passages**, rangs et scores. Vérifiez si les preuves des questions de développement sont retrouvées.
3. Produisez Q0 en renvoyant le premier passage, sans reformulation ni mécanisme d'abstention.

Une question sans réponse produit aussi un classement. Si le contexte dépasse la capacité du LLM, fixez sur le développement une sélection reproductible et sauvegardez les passages réellement transmis.

4.2 Produire Q1 et Q2

Utilisez le modèle que vous voulez en vous inspirant des notebooks du cours. Un accès personnel payant n'est pas requis.

Q1 : demandez une réponse à partir des passages et la citation de leurs identifiants. Fournissez leurs textes, pas seulement leurs URL.

Q2 : imposez l'usage exclusif des passages, le signalement de l'information insuffisante, la préservation des nombres et négations, et les citations. Expliquez ces consignes.

Q1 et Q2 reçoivent les mêmes passages, dans le même ordre, avec le même modèle, les mêmes paramètres et une longueur comparable. Réglez les prompts sur le développement ; conservez les réponses imparfaites pour l'analyse.

5 Évaluer les outils NLP

Comparez vos méthodes sur les **mêmes données et avec les mêmes conventions**. Précisez partition, effectifs et versions.

5.1 Les quatre tableaux à produire

Tâche	Mesures attendues
Extraction	Pour chaque méthode : vrais positifs, faux positifs, faux négatifs, précision, rappel et F1 sur les mentions ; résultats globaux et par catégorie, temps mesuré.
Négation	Sur les 10 exemples de test : matrice de confusion, précision, rappel et F1 par classe, moyenne des deux F1.
Recherche QA	Sur les questions répondables : Hit@5, rappel des passages justificatifs annotés à 5 et contrôle de la couverture des éléments attendus.
Réponses QA	Pour Q0/Q1/Q2 : BLEU, ROUGE-1/2/L et analyse manuelle de l'exactitude, de la complétude, des citations et des abstentions.

5.2 Interpréter correctement les scores

En extraction, une mention est correcte si **son document, ses bornes et son type** correspondent à la référence. Prédire « douleur » pour « douleur thoracique » produit un faux positif et un faux négatif. Le score global additionne les comptes avant les ratios.

En recherche, **Hit@5** indique la proportion de questions pour lesquelles au moins une preuve est retrouvée parmi les cinq premiers passages. Le **rappel à 5** mesure la part des preuves annotées retrouvée, puis est moyenné par question. Pour une réponse nécessitant plusieurs passages, vérifiez aussi que tous les éléments utiles sont présents.

BLEU et ROUGE mesurent un recouvrement textuel, pas la vérité d'une réponse. Ils sont calculés sur les questions répondables ; les citations sont retirées pour ce calcul puis évaluées séparément. Utilisez les scripts du cours avec les mêmes options pour Q0/Q1/Q2. Les formules, échelles et conventions de calcul sont précisées dans le guide pratique.

5.3 Examiner les réponses et expliquer les erreurs

Les deux membres évaluent séparément les **30 réponses finales** (10 questions, 3 configurations), puis résolvent leurs désaccords. La grille du guide précise : exactitude de 0 à 2, proportion d'éléments attendus présents, citations et abstentions. Une citation doit soutenir l'affirmation.

Présentez **des erreurs d'extraction**, **des cas difficiles de négation** et **des analyses comparatives de QA**. Si les erreurs sont peu nombreuses, analysez celles observées et des cas limites. En QA, cherchez à distinguer un passage manqué, une réponse incomplète, une affirmation non soutenue, une absence d'information et un désaccord entre score automatique et lecture humaine.

Rapportez effectifs, ressources et temps. Toute correction de référence doit être justifiée par les sources, versionnée et appliquée à toutes les configurations, sans modifier leurs prédictions ni réglages.

6 Organisation et rendus

6.1 Calendrier

Le projet comporte **trois jalons** : extraction (E), données et recherche QA (QA1), réponses et comparaison QA (QA2). Les ressources sont mises à disposition au fil des séances.

Date	Étape	Travail à remettre ou à présenter
09/10	Jalon E	Extraction, négation, résultats et synthèse de 2 à 3 pages. Présenter aussi trois documents et cinq questions annotées pour valider le cadrage QA.
23/10	Jalon QA1	Documents et passages, 20 questions DEV et 10 questions TEST annotées dans deux fichiers distincts ; recherche évaluée sur DEV et synthèse de 2 à 3 pages.
06/11	Gel du QA	En fin de TD : code, données, recherche, modèle, prompts et paramètres figés après les essais sur DEV.
13/11	Jalon QA2 et soutenances	Dépôt final complet, réponses Q0/Q1/Q2, scores, analyse manuelle, rapport et présentation orale.

6.2 Fichiers et rapport

Nommez les archives `NOM1_NOM2_E.zip`, `NOM1_NOM2_QA1.zip` et `NOM1_NOM2_final.zip`. Le dépôt final regroupe les deux tâches : notebooks ou code, données redistribuables ou procédure d'accès, paramètres, prédictions, tableaux de résultats et rapport.

Un **README** donne l'ordre d'exécution, les dépendances et versions, les ressources reprises et les fichiers produits. Les fichiers de code (.py ou .ipynb) doivent être lisibles et réexécutables depuis un état initial propre. Fournissez les sorties sauvegardées pour les calculs coûteux et déclarez les aides utilisées, y compris les IA generatives.

Le **rapport final comporte 8 à 12 pages hors annexes** : objectifs, données, méthodes, protocoles, comparaisons, erreurs, coûts et limites. Distinguez résultats obtenus et perspectives. Les corpus complets et sorties détaillées restent dans les fichiers zip joints.

6.3 Soutenance

Prévoyez **15 minutes de présentation et 10 minutes de questions**. Présentez une comparaison d'extraction et une comparaison de QA, avec des exemples d'erreurs et les limites principales. Les deux membres interviennent.

7 Barème

7.1 Répartition de la note

Réalisations : 40 % ; rapport : 30 % ; soutenance : 30 % Les trois jalons sont notés sur 20 et ont le même poids. Avec $J = (E + QA1 + QA2)/3$, et R, S, les notes sur 20 du rapport et de l'oral :

$$N = 0{,}40\,(J) + 0{,}30R + 0{,}30S.$$

Le QA représente deux jalons, car la construction des données et la comparaison des réponses sont deux étapes évaluées.

7.2 Rapport et soutenance

Rapport	**/20**
Définition des tâches, périmètres et exemples	3
Description des corpus et de la construction des annotations QA	4
Synthèse des comparaisons et des décisions	5
Analyse des erreurs, limites et coûts	4
Clarté, références et reproductibilité	4

Soutenance	**/20**
Présentation claire des deux outils et de leurs données	5
Explication des méthodes et de leur comparaison	6
Réponses aux questions et compréhension du code réutilisé	6
Analyse des limites et améliorations	3

7.3 Comment le travail est apprécié

Les points sont attribués **critère par critère**. Une partie obligatoire absente ne reçoit pas les points de sa réalisation, mais les éléments évaluables des autres critères sont pris en compte. Il n'y a pas de plafond global automatique pour une partie manquante.

Aucun seuil de performance n'est imposé. Un résultat faible peut accompagner un bon travail si le protocole est correct, les erreurs comprises et les limites expliquées. Les moyens de calcul personnels, la taille du modèle et le choix d'un corpus original ne donnent pas de points supplémentaires.

Le socle, avec **au moins deux catégories d'extraction**, suffit pour obtenir tous les points. Les approfondissements ne disposent pas de points réservés ; ils peuvent alimenter l'analyse au même titre que les expériences du socle. Une amélioration envisagée peut rester une perspective argumentée.

Citez les textes, corpus, bibliothèques, modèles, notebooks et aides utilisés. Les choix et résultats doivent pouvoir être expliqués par les deux membres du binôme.